PROJEKTOWANIE EFEKTYWNYCH ALGORYTMÓW

ZADANIE 3

PROWADZĄCY:
DR INŻ. JAROSŁAW MIERZWA

AUTOR:
BARTOSZ RUDNIK 248893

TERMIN ZAJĘĆ:
PN 15:15 – 16:55

WROCŁAW, 18.01.2021 r.

1. Opis problemu

Problem Komiwojażera (ang. Travelling salesman problem, TSP) jest to problem obliczeniowy polegający na wyznaczeniu w grafie takiego cyklu, który zawierać będzie wszystkie wierzchołki znajdujące się w grafie, każdy z tych wierzchołków odwiedzony zostanie wyłącznie jeden raz, a koszt tego cyklu będzie jak najmniejszy. Problem ten możemy wyobrazić sobie jako pracę kuriera, który na początku dnia pracy wyrusza z siedziby firmy i musi dostarczyć przesyłki do wyznaczonych miejsc, a następnie wrócić z powrotem do siedziby firmy. Rozwiązaniem problemu w przypadku pracy kuriera jest wyznaczenie mu drogi, która maksymalnie zminimalizuje koszty jego pracy. Jeśli spojrzymy na problem Komiwojażera z bardziej formalnej, matematycznej perspektywy to możemy go opisać jako problem polegający na znalezieniu minimalnego cyklu Hamiltona w pełnym grafie ważonym. Cykl Hamiltona jest to taki cykl w grafie, w którym każdy z wierzchołków grafu oprócz wierzchołka startowego jest odwiedzany wyłącznie raz. Problem Komiwojażera możemy podzielić na symetryczny problem komiwojażera, w którym odległość pomiędzy dowolnym miastem A i B jest taka sama jak odległość między miastem B i A oraz asymetryczny problem Komiwojażera, w którym odległości pomiędzy miastami A i B oraz B i A mogą być różne. Największą trudnością na jaką możemy natrafić podczas rozwiązywania problemu komiwojażera jest liczba danych jaką musimy przeanalizować. Przykładowo jeśli badany przez nas graf ma ‘n’ wierzchołków to jeśli chcemy zbadać wszystkie możliwe cykle w grafie to otrzymamy (n – 1)! możliwych kombinacji. Prowadzi to do otrzymania złożoności obliczeniowej wynoszącej O((n – 1)!) co oznacza, że dla większych wartości n problem ten będzie nierozwiązywalny. Problem komiwojażera należy do problemów NP-trudnych, czyli nie są znane algorytmy, które są w stanie wyznaczyć rozwiązanie tego problemu w wielomianowej złożoności obliczeniowej. Trzecie zadanie projektowe polegało na zaimplementowaniu algorytmu genetycznego rozwiązującego problem komiwojażera. Algorytm Genetyczny należy do grupy algorytmów ewolucyjnych. Algorytm Genetyczny swoim działaniem naśladuje procesy ewolucyjne gatunków znane ze świata rzeczywistego. Swoją pracę algorytm genetyczny rozpoczyna od wytworzenia początkowej populacji osobników. Następnie stosowane są: metody selekcji mające na celu wybrać spośród populacji osobników przeznaczonych do rozmnażania, metody krzyżowania tworzące nowe osobniki, a także metody mutacji wprowadzające modyfikacje w wytworzonych nowych osobnikach.

2. Generowanie początkowej populacji

Algorytm swoje działanie rozpoczyna od wygenerowania początkowej populacji osobników o zadanym przez użytkownika rozmiarze. W swojej implementacji algorytmu genetycznego do generacji początkowej populacji użyłem:

1) Algorytmu Zachłannego (1 osobnik)
Algorytm zachłanny dokonuje pełnego przeglądu sąsiedztwa bieżącego rozwiązania x aż do momentu gdy w sąsiedztwie rozwiązania x nie istnieje rozwiązanie o mniejszej wartości funkcji celu. Algorytm zachłanny zwraca rozwiązanie będące lokalnym minimum, przeszukując przy tym bardzo niewielką część przestrzeni wszystkich rozwiązań.

```
public int [] greedy(int [][] graph){
  int [] route = new int[numberOfVertex + 1];
  int [] resultRoute = new int[numberOfVertex + 1];
  boolean check;
```

```
int oldBestIndex;
int actualBestIndex = 0;
for(int i = 0; i < numberOfVertex; i++){
    int bestCost = Integer.MAX_VALUE;
    oldBestIndex = actualBestIndex;
    for(int j = 0; j < numberOfVertex; j++){
        check = true;
        if(j != oldBestIndex){
            for(int g = 0; g <= i; g++){
                if (j == route[g]) {
                    check = false;
                    break;
                }
            }
            if(graph[oldBestIndex][j] < bestCost && check){
                bestCost = graph[oldBestIndex][j];
                actualBestIndex = j;
            }
        }
    }
    route[i] = actualBestIndex;
    resultRoute[i] = oldBestIndex;
}
resultRoute[numberOfVertex] = 0;
return resultRoute;
}
```

2) Algorytmu zachłanno-losowego (80% populacji początkowej)

Algorytm zachłanno-losowy jest modyfikacją algorytmu zachłannego polegająca na wygenerowaniu pierwszych n wierzchołków w sposób losowy i dla w ten sposób częściowo wyznaczonej ścieżki użycia algorytmu zachłannego w celu jej uzupełnienia.

```
public int [] randomGreedy(int [][] graph, int n) {
        Random random = new Random();
        int [] route = new int[numberOfVertex + 1];
        int [] resultRoute = new int[numberOfVertex + 1];
        boolean check;
        int oldBestIndex;
        int actualBestIndex = 0;
        route[0] = 0;
        resultRoute[0] = 0;
        for(int i = 1; i <= n; i++){
            boolean test = false;
            while(!test) {
                int count = 0;
                int next = random.nextInt(numberOfVertex - 2) + 1;
                for(int j = 0; j < i; j++)
                    if(resultRoute[j] == next)
                        count++;
                if(count == 0) {
                    resultRoute[i] = next;
                    route[i] = next;
                    test = true;
                }
            }
        }
        boolean test = false;
        while(!test) {
            int count = 0;
            int next = random.nextInt(numberOfVertex - 2) + 1;
```

```
                for(int j = 0; j < n; j++)
                    if(resultRoute[j] == next)
                        count++;
                if(count == 0) {
                    actualBestIndex = next;
                    test = true;
                }
            }
            for(int i = n + 1; i < numberOfVertex; i++){
                int bestCost = Integer.MAX_VALUE;
                oldBestIndex = actualBestIndex;
                for(int j = 0; j < numberOfVertex; j++){
                    check = true;
                    for(int g = 0; g <= i; g++){
                        if (j == resultRoute[g]) {
                           check = false;
                           break;
                        }
                    }
                    if(graph[oldBestIndex][j] < bestCost && check && j !=
oldBestIndex){
                       bestCost = graph[oldBestIndex][j];
                       actualBestIndex = j;
                    }
                }
                route[i] = actualBestIndex;
                resultRoute[i] = oldBestIndex;
            }
            resultRoute[numberOfVertex] = 0;
            return resultRoute;
        }
```

3) algorytmu losowego (pozostali osobnicy)

Algorytm ten korzysta z generatora liczb pseudolosowych w celu wykonania (n – 1) zamian losowo wyznaczonych pozycji wierzchołków w tablicy, gdzie n jest rozmiarem populacji.

```
public int [] shuffleArray(int[] array)    {
  int index, temp;
  Random random = new Random();
  int [] tmpArray = new int[array.length - 2];
  if (tmpArray.length >= 0)
      System.arraycopy(array, 1, tmpArray, 0, tmpArray.length);
  for (int i = tmpArray.length - 1; i > 0; i--)        {
      index = random.nextInt(i + 1);
      temp = tmpArray[index];
      tmpArray[index] = tmpArray[i];
      tmpArray[i] = temp;
  }
  if (tmpArray.length >= 0)
      System.arraycopy(tmpArray, 0, array, 1, tmpArray.length);
  return  array;
}
```

3. Metody selekcji

Metody selekcji służą do wyselekcjonowania z populacji osobników, którzy w dalszej części działania algorytmu zostaną użyci w metodach krzyżowania do stworzenia nowego pokolenia osobników. W swojej implementacji algorytmu genetycznego przygotowałem

trzy metody selekcji rodziców:

1) Selekcja turniejowa

W selekcji turniejowej tworzymy n turniejów, do każdego z turniejów losujemy k osobników. Następnie z każdego z turniejów wybieramy najlepszego osobnika i tworzymy ponownie turniej dla wszystkich najlepszych osobników. Wynikiem działania selekcji turniejowej jest zwrócenie osobnika, który okazał się najlepszy w turnieju dla najlepszych osobników

```
public int[] tournament(int numberOfVertex, int populationSize, int n)
{
  Random random = new Random();
  int[] finalBest = new int[numberOfVertex + 2];
  int finalBestCost = Integer.MAX_VALUE;
  for (int j = 0; j < n; j++) {
      int[] actualBest = new int[numberOfVertex + 2];
      int actualBestCost = Integer.MAX_VALUE;
      boolean[] test = new boolean[populationSize];
      for (int i = 0; i < n; i++) {
          int randomIndex = random.nextInt(populationSize - 1);
          if (test[randomIndex]) {
              i--;
              continue;
          } else
              test[randomIndex] = true;
          int[] currentRoute = population.get(randomIndex);
          if (currentRoute[currentRoute.length-1]<actualBestCost){
              actualBestCost = currentRoute[currentRoute.length - 1];
              actualBest = currentRoute.clone();
          }
      }
      if (actualBest[actualBest.length - 1] < finalBestCost) {
          finalBestCost = actualBest[actualBest.length - 1];
          finalBest = actualBest.clone();
      }
  }
  return finalBest;
  }
```

2) Selekcja koła ruletki

Stosując selekcję koła ruletki dla każdego z osobników należących do naszej populacji musimy wyznaczyć ich funkcję zdatności. Wartość funkcji zdatności określa zdatność danego osobnika do rozmnożenia. Im większa jest wartość zdatności dla danego osobnika tym większa jest szansa wybrania go jako rodzica. Do określenia wartości funkcji zdatności możemy wykorzystać wzór: $funkcjaZdatnosci = \frac{1}{k}$, gdzie k jest kosztem przejścia ścieżki badanego osobnika. Po wyznaczeniu wartości funkcji zdatności dla wszystkich osobników w populacji należy te wartości zsumować, a w dalszej kolejności obliczyć każdemu osobnikowi prawdopodobieństwo wyboru poprzez podzielenie wartości jego funkcji zdatności przez sumę wszystkich funkcji zdatności.

```
public int[] roulette(int populationSize) {
        Random random = new Random();
        List<int[]> tmpPopulation = new ArrayList<>(population);
        double[] fitnessValue = new double[populationSize];
        double totalFitnessValue = 0.0;
        double fitnessSum = 0.0;
        int returnIndex = 0;
        sortPopulation(tmpPopulation);
```

```
        for (int i = 0; i < populationSize; i++) {
            int[] route = tmpPopulation.get(i);
            int pathCost = route[route.length - 1];
            fitnessValue[i] = 1 / (double) pathCost;
        }
        for (int i = 0; i < populationSize; i++)
            totalFitnessValue += fitnessValue[i];
        for (int i = 0; i < populationSize; i++)
            fitnessValue[i] /= totalFitnessValue;
        double testValue = random.nextDouble();
        for (int i = 0; i < populationSize; i++) {
            fitnessSum += fitnessValue[i];
            if (fitnessSum >= testValue) {
                returnIndex = i;
                break;
            }
        }
        return tmpPopulation.get(returnIndex);
         }
```

3) Selekcja rankingowa

Selekcja rankingowa podobnie jak selekcja koła ruletki korzysta z funkcji zdatności jednak jej wartość jest obliczana z innego wzoru niż to ma miejsce w przypadku selekcji koła ruletki. Prawdopodobieństwo wyboru danego osobnika w selekcji rankingowej zależy od miejsca tego osobnika w rankingu. Ranking ten sortuje wszystkie osobniki należące do populacji w kolejności od osobnika o najmniejszym koszcie przejścia ścieżki do osobnika o największym koszcie przejścia ścieżki. Wzór, który możemy wykorzystać do obliczenia wartości funkcji zdatności dla danego osobnika w selekcji rankingowej jest postaci: $funkcjaZdatnosci = \frac{popSize - r}{popSize(popSize-1)}$, gdzie popSize jest rozmiarem populacji, a r jest pozycją w rankingu danego osobnika.

```
public int[] ranking(int populationSize) {
        Random random = new Random();
        List<int[]> tmpPopulation = new ArrayList<>(population);
        double[] fitnessValue = new double[populationSize];
        double totalFitnessValue = 0.0;
        double fitnessSum = 0.0;
        int returnIndex = 0;
        sortPopulation(tmpPopulation);
        for (int i = 0; i < populationSize; i++) {
            fitnessValue[i] = (populationSize - i) / (double)
populationSize * (populationSize - 1);
        }
        for (int i = 0; i < populationSize; i++)
            totalFitnessValue += fitnessValue[i];
        int helpRank = populationSize;
        for (int i = 0; i < populationSize; i++) {
            fitnessValue[i] = helpRank / totalFitnessValue;
            helpRank--;
        }
        double testValue = random.nextDouble();
        for (int i = 0; i < populationSize; i++) {
            fitnessSum += fitnessValue[i];
            if (fitnessSum >= testValue) {
                returnIndex = i;
                break;
            }
        }
```

```
        return tmpPopulation.get(returnIndex);
    }
```

4. Metody krzyżowania

Krzyżowanie polega na łączeniu cech osobników wybranych przez metody selekcji. Celem zastosowania metod krzyżowania jest wygenerowanie nowego pokolenia osobników, które dzięki wyborowi odpowiednich rodziców okaże się pokoleniem dającym lepsze wyniki niż poprzednie pokolenia. W mojej implementacji algorytmu genetycznego umieściłem następujące algorytmy krzyżowania: single-point crossover, two-point crossover, cycle crossover, cycle2 crossover, order crossover, partially mapped crossover, sequential constructive crossover oraz enhanced sequential constructive crossover. W dalszej części opisane zostaną Order Crossover oraz Enhanced Sequential Crossover, które podczas testów uzyskały najlepsze wyniki.

1) Order Croossover

W pierwszej kolejności należy wyznaczyć dwa indeksy i oraz j takie, że (i > j), pomiędzy którymi w osobnikach będących rodzicami stworzona zostanie sekcja dopasowania. Dane znajdujące się w sekcji dopasowania pierwszego rodzica kopiujemy do tworzonego potomka i umieszczamy na tych samych pozycjach co w pierwszym rodzicu. Następnie rozpoczynając od indeksu (i + 1) w przypadku gdy nie występuje kolizja (czyli gdy w dziecku umieszczony jest już kopiowany element) kopiujemy do dziecka dane z drugiego rodzica. W przypadku dojścia do końca ścieżki wracamy na jej początek. Dane są kopiowane do dziecka aż do momentu dojścia do początku sekcji dopasowania.

Przykład:
1. Wyznaczenie sekcji dopasowania
$rodzic1 = 0\ 2\ |3\ 1\ 4|\ 6\ 5\ 0$
$rodzic2 = 0\ 6\ |1\ 2\ 3|\ 5\ 4\ 0$
2. Skopiowanie danych z sekcji dopasowania pierwszego rodzica do dziecka
$dziecko = 0\ x\ |3\ 1\ 4|\ x\ x\ 0$
3. Skopiowanie danych z drugiego rodzica do dziecka
$dziecko = 0\ x\ |3\ 1\ 4|\ 5\ 6\ 0$
Najpierw z drugiego rodzica kopiujemy '5', potem pomijamy '4' ponieważ znajduje się już w dziecku. Ponieważ doszliśmy do końca ścieżki drugiego rodzica, a nie uzupełniliśmy jeszcze wszystkich elementów dziecka to wracamy na początek drugiego rodzica.
$dziecko = 0\ 2\ |3\ 1\ 4|\ 5\ 6\ 0$
Kopiując do dziecka element 2 doszliśmy tym samym do miejsca rozpoczęcia sekcji dopasowania, czyli skończyliśmy proces tworzenia dziecka. Wynikowa struktura stworzonego dziecka przedstawia się następująco:
$\boldsymbol{dziecko = 0\ 2\ |3\ 1\ 4|\ 5\ 6\ 0}$

Implementacja algorytmu order crossover w języku Java użyta w projekcie:

```
public int[] order(int[][] graph, int[] firstParent, int[]
secondParent, int numberOfVertex) {
  int[] child = new int[numberOfVertex + 2];
  Random random = new Random();
  int i = 0;
  int j = 0;
  while (i == j) {
      i = random.nextInt(numberOfVertex - 2) + 1;
      j = random.nextInt(numberOfVertex - 2) + 1;
  }
  if (j > i) {
```

```
            int tmp = i;
            i = j;
            j = tmp;
        }
        int[] chosenVertexes = new int[i - j + 1];
        int tmpIndex = 0;
        for (int start = j; start <= i; start++) {
            chosenVertexes[tmpIndex] = firstParent[start];
            tmpIndex++;
        }
        tmpIndex = i + 1;
        int tmpIndex2 = i + 1;
        if (tmpIndex == secondParent.length - 2)
            tmpIndex = 1;
        if (tmpIndex2 == secondParent.length - 2)
            tmpIndex2 = 1;
        for (int k = 0; k < numberOfVertex; k++) {
            int tmpVertex = secondParent[tmpIndex2];
            boolean test = true;
            for (int chosenVertex : chosenVertexes) {
                if (tmpVertex == chosenVertex) {
                    test = false;
                    break;
                }
            }
            if (test) {
                child[tmpIndex] = tmpVertex;
                tmpIndex++;
            }
            tmpIndex2++;
            if (tmpIndex == secondParent.length - 2)
                tmpIndex = 1;
            if (tmpIndex2 == secondParent.length - 2)
                tmpIndex2 = 1;
        }
        tmpIndex2 = 0;
        for (int k = j; k <= i; k++) {
            child[k] = chosenVertexes[tmpIndex2];
            tmpIndex2++;
        }
        child[0] = 0;
        child[child.length - 2] = 0;
        child[child.length - 1] = utils.getRouteCost(graph, child);
        return child;
    }
```

2) Enhanced Sequential Crossover

Jest to algorytm krzyżowania, który w swoim działaniu oprócz wykorzystania rodziców, korzysta także z zadanej macierzy kosztów przejścia w celu stworzenia potomków lepszej jakości. Algorytm swoje działanie rozpoczyna od skopiowania pierwszego elementu z pierwszego rodzica do dziecka. Następnie w obu rodzicach wyznaczane są elementy występujące na następnej pozycji po elemencie skopiowanym do dziecka. Po wyznaczeniu tych elementów w obu rodzicach wybieramy element z tego rodzica, dla którego obliczony przewidywany koszt będzie mniejszy. Operacje tą wykonujemy według wzoru:

$\min(k_{w1w2} + k_{w2a}, k_{w1w3} + k_{w3b})$, gdzie:
$w1 - poprzednio\ dodany\ do\ dziecka\ wierzchołek$
$w2 - rozważany\ wierzchołek\ z\ pierwszego\ rodzica$
$w3 - rozważany\ wierzchołek\ z\ drugiego\ rodzica$
k_{ab} – koszt przejścia z wierzchołka a do wierzchołka b
k_{w2a} – najmniejszy z kosztów przejścia z wierzchołka w2 do dowolnego nieznajdującego się w dziecku wierzchołka
k_{w3b} – najmniejszy z kosztów przejścia z wierzchołka w3 do dowolnego nieznajdującego się w dziecku wierzchołka

Procedura wyboru kolejnych wierzchołków kopiowanych do dziecka odbywa się analogicznie aż do pełnego wypełnienia ścieżki dziecka.

Przykład:
1. Dane wejściowe

	0	1	2	3	4	5
0	-1	45	23	12	67	29
1	45	-1	78	42	90	56
2	23	78	-1	34	38	22
3	12	42	34	-1	78	99
4	67	90	38	78	-1	5
5	29	56	22	99	5	-1

$$rodzic1 \rightarrow 0\ 2\ 3\ 1\ 4\ 5\ 0$$
$$rodzic2 \rightarrow 0\ 5\ 1\ 3\ 2\ 4\ 0$$

2. Skopiowanie do dziecka pierwszego elementu z pierwszego rodzica

$$dziecko \rightarrow 0\ 2\ x\ x\ x\ x\ 0$$

3. Wyznaczenie elementów występujących po elemencie 2 i obliczenie przewidywanych kosztów

$$dla\ rodzic1 \rightarrow 3$$
$$dla\ rodzic2 \rightarrow 4$$
$$\min(34 + 42,\ 38 + 5)$$
$$\min(76, 43)$$

ponieważ $43 < 76$, to kolejnym dodanym do dziecka wierzchołkiem będzie 4.

$$dziecko \rightarrow\ 0\ 2\ 4\ x\ x\ x\ 0$$

4. Wyznaczenie elementów występujących po elemencie 4

$$dla\ rodzic1 \rightarrow 5$$
$$dla\ rodzic2 \rightarrow 1$$

ponieważ w rodzicu2 po elemencie 4 występuje element 0, który już znajduje się w dziecku musimy wybrać pierwszy nie występujący w dziecku element ze zbioru {1, 2, 3, 4, 5}.

$$\min(5 + 56, 90 + 42)$$
$$\min(61, 132)$$

ponieważ 61 < 132 to kolejnym elementem dodanym do dziecka będzie 5.

$$dziecko \rightarrow 0\ 2\ 4\ 5\ x\ x\ 0$$

Wykonujemy analogiczne kroki aż do momentu pełnego wypełnienia ścieżki dziecka.

5. Ostateczna struktura stworzonego dziecka

$$\boldsymbol{dziecko \rightarrow\ 0\ 2\ 4\ 5\ 1\ 3\ 0}$$

Implementacja algorytmu enhanced sequential constructive crossover w języku Java użyta w projekcie:

```
public int[] enhancedSequentialConstructive(int[][] graph, int[]
firstParent, int[] secondParent, int numberOfVertex) {
        int[] child = new int[numberOfVertex + 2];
        int position = 1;
        int addNode = firstParent[position];
        int firstNode;
        int secondNode;
        int firstParentIndex;
        int secondParentIndex;
        child[position] = addNode;
        position++;
        while (position < numberOfVertex) {
            firstParentIndex = sequentialIndex(numberOfVertex,
firstParent, addNode);
            secondParentIndex = sequentialIndex(numberOfVertex,
secondParent, addNode);
            firstNode = sequentialNode(numberOfVertex,
firstParentIndex, position, firstParent, child);
            secondNode = sequentialNode(numberOfVertex,
secondParentIndex, position, secondParent, child);
            int firstParentMin = minRowValue(firstNode, graph,
numberOfVertex, child);
            int secondParentMin = minRowValue(secondNode, graph,
numberOfVertex, child);
            if (graph[addNode][firstNode] + firstParentMin <
graph[addNode][secondNode] + secondParentMin) {
                child[position] = firstNode;
                addNode = firstNode;
            } else {
                child[position] = secondNode;
                addNode = secondNode;
            }
            position++;
        }
        child[0] = 0;
        child[child.length - 2] = 0;
        child[child.length - 1] = utils.getRouteCost(graph, child);
        return child;
    }
```

5. Metody mutacji

Mutacja wprowadza do osobników losowe zmiany, jej zadaniem jest wprowadzenie różnorodności w populacji czyli zabieganie przedwczesnej zbieżności algorytmu. Mutacje zachodzą z zadanym przez użytkownika prawdopodobieństwem. Zbyt małe

prawdopodobieństwo mutacji może spowodować zbyt dużą jednorodność populacji, zbyt duże prawdopodobieństwo mutacji może spowodować zbyt duże pogorszenie dobrych osobników wytworzonych podczas krzyżowania. W swojej implementacji algorytmu genetycznego przygotowałem czy algorytmu mutacyjne: swap, insert oraz reverse. Algorytmy insert oraz reverse pozwalały osiągnąć lepsze wyniki i to one będą opisane w dalszej części.

1) Insert

Funkcja insert(i, j) umieszcza wierzchołek o wartości 'i' na pozycji o indeksie 'j' w zadanej tablicy. Wywołanie funkcji insert (5, 2) dla ścieżki [0, 1, 2, 3, 4, 5, 0] zwróci następującą ścieżkę [0, 1, 5, 2, 3, 4, 0].

Implementacja funkcji insert() w języku JAVA wykorzystana do przeprowadzenia mutacji:

```
public int[] insertRoute(int[] route, int i, int j) {
        int indexI = 0;
        int tmp = 0;
        int[] tmpArray = new int[route.length];
        for (int k = 1; k < route.length - 1; k++) {
            if (route[k] == i) {
                indexI = k;
                break;
            }
        }
        if (indexI > j) {
            for (int k = j; k < route.length; k++) {
                if (route[k] != i)
                    tmpArray[k - tmp] = route[k];
                else
                    tmp = 1;
            }
            route[j] = i;
            if (route.length - (j + 1) >= 0)
                System.arraycopy(tmpArray, j + 1 - 1, route, j + 1,
route.length - (j + 1));
        } else {
            if (j - indexI >= 0)
                System.arraycopy(route, indexI + 1, route, indexI, j
- indexI);
            route[j] = i;
        }
        return route;
    }
```

2) Reverse

Funkcja reverse(i, j) wykonuje odwrócenie kolejności pomiędzy wierzchołkami o wartości 'i' oraz 'j', włącznie z wierzchołkiem o wartości 'i' i 'j'. Wywołanie funkcji reverse(1, 3) dla tablicy [0, 1, 2, 3, 4, 5, 0] zwróci tablicę [0, 3, 2, 1, 4, 5, 0].

Implementacja funkcji reverse() w języku JAVA wykorzystana w projekcie:

```
public int[] reverseRoute(int[] route, int i, int j) {
        int[] index = getIndex(route, i, j);
        int iIndex = index[0];
        int jIndex = index[1];
```

```
        if (iIndex < jIndex) {
            while (iIndex < jIndex) {
                int tmp = route[iIndex];
                route[iIndex] = route[jIndex];
                route[jIndex] = tmp;
                iIndex++;
                jIndex--;
            }
        } else {
            while (jIndex < iIndex) {
                int tmp = route[iIndex];
                route[iIndex] = route[jIndex];
                route[jIndex] = tmp;
                iIndex--;
                jIndex++;
            }
        }
        return route;
    }
```

6. Elitaryzm

Jest to mechanizm pozwalający zachować n najlepszych osobników ze starej populacji. Użytkownik może podać wartość parametru n w celu dopasowania go do badanego problemu. Zastosowanie mechanizmu elitaryzmu pozwala na zachowanie w populacji najlepiej dostosowane osobniki dzięki czemu nadal istnieje szansa, że będą mogły się rozmnożyć.

7. Algorytm Memetyczny

Jest to algorytm będący rozszerzeniem algorytmu genetycznego, oprócz operacji znanych w algorytmie genetycznym takich jak: operacje selekcji, krzyżowania oraz mutacji w algorytmie memetycznym dochodzi operacja lokalnej optymalizacji. Celem wykonywania lokalnej optymalizacji jest osiągnięcie lepszych rozwiązań. W mojej implementacji algorytmu genetycznego rozszerzenie memetyczne może zostać włączone lub wyłączone przez użytkownika. W metodzie wykonującej lokalną optymalizację w zależności od wyboru użytkownika wykorzystywana jest jedna z trzech dostępnych metod:
1) Insert
2) Swap
3) Reverse
Metody Insert oraz Reverse zostały opisane w rozdziale dotyczącym mutacji. Poniżej zamieszczony został opis funkcji swap:

Funkcja swap(i, j) zamienia miejscami wierzchołek o numerze ‘i’ z wierzchołkiem o numerze ‘j’ Wywołanie funkcji swap(3,5) dla tablicy wierzchołków [0, 1, 2, 3, 4, 5] zwróci następującą tablice: [0, 1, 2, 5, 4, 3]. Implementacja funkcji swap() w języku JAVA wykorzystana w projekcie:

```
public int[] swapRoute(int[] route, int i, int j) {
  int[] index = getIndex(route, i, j);
  int iIndex = index[0];
  int jIndex = index[1];
  int tmp = route[iIndex];
  route[iIndex] = route[jIndex];
  route[jIndex] = tmp;
```

```
    return route;
}
```

Metoda lokalnej optymalizacji przeszukuje sąsiedztwo danego użytkownika i zapamiętuje wykorzystane parametry, dla których udało się uzyskać najbardziej korzystny rezultat.

```
public int[] bestRoute(int[][] graph, int[] route, int numberOfVertex,
int mutationType) {
        int[] parameters = new int[2];
        int bestCost = Integer.MAX_VALUE;
        for (int i = 1; i < numberOfVertex - 1; i++) {
            for (int j = i + 1; j < numberOfVertex; j++) {
                int[] newRoute = route.clone();
                if (mutationType == 0)
                    newRoute = insertRoute(newRoute, i, j);
                else if (mutationType == 1)
                    newRoute = swapRoute(newRoute, i, j);
                else
                    newRoute = reverseRoute(newRoute, i, j);
                newRoute[newRoute.length - 1] =
utils.getRouteCost(graph, newRoute);
                if (newRoute[newRoute.length - 1] < bestCost) {
                    bestCost = newRoute[newRoute.length - 1];
                    parameters[0] = i;
                    parameters[1] = j;
                }
            }
        }
        return parameters;
    }
```

8. Przebieg działania algorytmu

Algorytm swoje działanie rozpoczyna od obliczenia wyznaczenie czasu zakończenia swojego działania, następnie generowana jest początkowa populacja. Rozmiar populacji jest parametrem ustawianym przez użytkownika. W dalszej kolejności wyznaczane jest najlepsze dotychczasowe rozwiązanie. Kolejnym krokiem w algorytmie jest pętla while działająca do momentu osiągnięcia warunku stopu algorytmu. W pętli tej znajduje się druga pętla while służąca do generacji nowych osobników. W zależności od wyboru użytkownika rodzice mogą być wybrani przy pomocy selekcji turniejowej, selekcji rankingowej lub selekcji koła ruletki. Następnie jeśli spełniony został warunek prawdopodobieństwa krzyżowania to przy pomocy wyznaczonych wcześniej rodziców powstają nowe osobniki. Po wytworzeniu wymaganej liczby osobników nowej, tymczasowej populacji algorytm przechodzi do pętli for, w której odbywa się mutacja osobników należących do nowo utworzonej, tymczasowej populacji. Mutacja zachodzi jeśli został spełniony warunek prawdopodobieństwa mutacji. Prawdopodobieństwo mutacji oraz prawdopodobieństwo krzyżowania są parametrami ustawianymi przez użytkownika. Po zakończeniu procesu mutacji, w zależności od wyboru użytkownika może zostać przeprowadzony proces lokalnej optymalizacji. Kolejnym krokiem jest dodanie osobników należących do tymczasowej populacji do populacji głównej z zachowaniem zasady elitaryzmu. Ostatnim krokiem wykonywanym w głównej pętli while jest sprawdzenie czy nowo wytworzona populacja zawiera w sobie lepszego osobnika niż dotychczasowy najlepszy osobnik. Po spełnieniu warunku stopu algorytmu wypisywana jest ścieżka należąca do najlepszego znalezionego osobnika oraz koszt jej przejścia.

```
    public int[] algorithm(int[][] graph, int numberOfVertex, int
    seconds, int populationSize, int exclusivity, int selectionType, int
    crossoverType, double mutationChance, int mutationType, int
    memeticType, double crossoverChance, boolean memetic) {
      Random random = new Random();
      Crossover crossover = new Crossover(numberOfVertex);
      Mutation mutation = new Mutation(numberOfVertex);
      Selection selection = new Selection(population);
      int[] bestRoute = new int[numberOfVertex + 2];
      bestRoute[bestRoute.length - 1] = Integer.MAX_VALUE;
      generatePopulation(graph, numberOfVertex, populationSize);
      long finishTime = System.currentTimeMillis() + seconds * 1000L;
      for (int[] route : population) {
          if (route[route.length - 1] < bestRoute[bestRoute.length -
1]) {
              bestRoute = route.clone();
          }
      }
      while (System.currentTimeMillis() < finishTime) {
          int[] firstParent;
          int[] secondParent;
          List<int[]> newPopulation = new ArrayList<>();
          while (newPopulation.size() < (populationSize -
exclusivity)) {
              double chance = random.nextDouble();
              int[] child1;
              int[] child2;
              if (selectionType == 0) {
                  firstParent = selection.tournament(numberOfVertex,
population.size(), 2);
                  secondParent = selection.tournament(numberOfVertex,
population.size(), 2);
              } else if (selectionType == 1) {
                  firstParent = selection.roulette(population.size());
                  secondParent =
selection.roulette(population.size());
              } else {
                  firstParent = selection.ranking(population.size());
                  secondParent = selection.ranking(population.size());
              }
              if (crossoverChance >= chance) {
                  if (crossoverType == 0) {
                      child1 = crossover.twoPoint(graph, firstParent,
secondParent, numberOfVertex);
                      child2 = crossover.twoPoint(graph, secondParent,
firstParent, numberOfVertex);
                  } else if (crossoverType == 1) {
                      child1 = crossover.order(graph, firstParent,
secondParent, numberOfVertex);
                      child2 = crossover.order(graph, secondParent,
firstParent, numberOfVertex);
                  } else if (crossoverType == 2) {
                      child1 = crossover.partiallyMapped(graph,
firstParent, secondParent, numberOfVertex);
                      child2 = crossover.partiallyMapped(graph,
secondParent, firstParent, numberOfVertex);
                  } else if (crossoverType == 3) {
                      child1 = crossover.cycle(graph, firstParent,
secondParent, numberOfVertex);
```

```
                        child2 = crossover.cycle(graph, secondParent,
firstParent, numberOfVertex);
                    } else if (crossoverType == 4) {
                        int[][] children = crossover.cycle2(graph,
firstParent, secondParent, numberOfVertex);
                        child1 = children[0];
                        child2 = children[1];
                    } else if (crossoverType == 5) {
                        child1 = crossover.sequentialConstructive(graph,
firstParent, secondParent, numberOfVertex);
                        child2 = crossover.sequentialConstructive(graph,
secondParent, firstParent, numberOfVertex);
                    } else if (crossoverType == 6) {
                        child1 =
crossover.enhancedSequentialConstructive(graph, firstParent,
secondParent, numberOfVertex);
                        child2 =
crossover.enhancedSequentialConstructive(graph, secondParent,
firstParent, numberOfVertex);
                    } else {
                        child1 = crossover.singlePoint(graph,
firstParent, secondParent, numberOfVertex);
                        child2 = crossover.singlePoint(graph,
secondParent, firstParent, numberOfVertex);
                    }
                    newPopulation.add(child1);
                    newPopulation.add(child2);
                }
            }
            for (int[] route : newPopulation) {
                double chance = random.nextDouble();
                if (mutationChance >= chance) {
                    int start = 0;
                    int end = 0;
                    while (start == end) {
                        start = random.nextInt(numberOfVertex - 2) + 1;
                        end = random.nextInt(numberOfVertex - 2) + 1;
                    }
                    if (mutationType == 0)
                        route = mutation.insertRoute(route, start, end);
                    if (mutationType == 1)
                        route = mutation.swapRoute(route, start, end);
                    if (mutationType == 2)
                        route = mutation.reverseRoute(route, start,
end);
                    route[route.length - 1] = utils.getRouteCost(graph,
route);
                }
            }
            if (memetic) {
                for (int[] route : newPopulation) {
                    int[] parameters = mutation.bestRoute(graph, route,
numberOfVertex, memeticType);
                    if (memeticType == 0)
                        route = mutation.insertRoute(route,
parameters[0], parameters[1]);
                    else if (memeticType == 1)
                        route = mutation.swapRoute(route, parameters[0],
parameters[1]);
                    else
```

```
                        route = mutation.reverseRoute(route,
parameters[0], parameters[1]);
                    route[route.length - 1] = utils.getRouteCost(graph,
route);
                }
            }
            clearPopulation(population.size(), exclusivity);
            population.addAll(newPopulation);

            for (int[] route : population) {
                if (route[route.length - 1] < bestRoute[bestRoute.length
- 1]) {
                    bestRoute = route.clone();
                }
            }
        }
        for (int i : bestRoute)
            System.out.print(i + " ");
        return bestRoute;
    }
```

9. Plan eksperymentu pomiarowego

Algorytmy zostały zaimplementowane przy użyciu języka programowania JAVA. Pomiary przeprowadzone zostały w systemie operacyjnym Ubuntu 20.04.01 LTS. Procesor, na którym przeprowadzono pomiary to Intel Core i5-8250u o bazowej częstotliwości 1,60 Ghz.

Eksperyment pomiarowy został przeprowadzony dla danych zawartych w trzech plikach:
1) ftv47.atsp
2) ftv170.atsp
3) rbg403.atsp

Dla wymienionych plików przeprowadzone zostały pomiary błędu względnego. Dla algorytmu genetycznego wykonane zostały pomiary badające wpływ wielkości populacji na otrzymywane wyniki. Dla najlepszego rozmiaru populacji uzyskanego podczas tych pomiarów zostały również przeprowadzone pomiary wpływu współczynnika mutacji na otrzymywane wyniki oraz wpływu współczynnika krzyżowania na wyniki. Dla pliku ftv47.atsp czas wykonywanie się algorytmu ustawiony był na 20 sekund, dla pliku ftv170.atsp było to 40 sekund, a dla pliku rbg403.atsp było to 60 sekund.

10. Eksperyment pomiarowy

10.1 Badanie wpływu wielkości populacji na otrzymywane wyniki

ftv47.atsp			
Krzyżowanie OX, Mutacja Insert			
Rozmiar Populacji	50	150	300
	2130	1989	2083
	2125	1965	2190
	2091	1919	2020
	2176	1922	2102
	2153	2013	2172
	2070	2072	2142
	2095	1892	2028
	2172	1999	1971
	2195	1965	2091
	2253	2009	2141

Tabela 1 Wpływ rozmiaru populacji na wyniki dla pliku ftv47.atsp, krzyżowania OX i mutacji Insert

ftv47.atsp			
Krzyżowanie OX, Mutacja Reverse			
Rozmiar Populacji	50	150	300
	2261	2011	2252
	2261	2078	2164
	2289	1929	2029
	2261	2016	2193
	2314	2028	2277
	2127	2042	2159
	2311	2065	2205
	2281	2051	2041
	2261	2077	2153
	2228	1951	2254

Tabela 2 Wpływ rozmiaru populacji na wyniki dla pliku ftv47.atsp, krzyżowania OX i mutacji Reverse

ftv47.atsp			
Krzyżowanie ESCX, Mutacja Insert			
Rozmiar Populacji	50	150	300
	2160	1930	2019
	2121	1923	1995
	2138	1962	1970
	2051	1826	1976
	2112	1919	1999
	1962	1925	2031
	2164	1912	2014
	2030	1976	2050
	2145	1902	2003
	2024	1934	1984

Tabela 3 Wpływ rozmiaru populacji na wyniki dla pliku ftv47.atsp, krzyżowania ESCX i mutacji Insert

ftv47.atsp			
Krzyżowanie ESCX, Mutacja Reverse			
Rozmiar Populacji	50	150	300
	2205	1987	2061
	2302	1919	2094
	2217	1967	2019
	2191	1947	2078
	2145	2062	2157
	2287	1916	2056
	2193	1949	2002
	2207	2025	2002
	2277	1913	2021
	2302	1931	2132

Tabela 4 Wpływ rozmiaru populacji na wyniki dla pliku ftv47.atsp, krzyżowania ESCX i mutacji reverse

ftv170.atsp			
Krzyżowanie OX, Mutacja Insert			
Rozmiar Populacji	50	150	300
	3552	3422	3402
	3526	3325	3381
	3339	3463	3411
	3519	3394	3430
	3498	3394	3494
	3450	3400	3455
	3535	3481	3773
	3370	3370	3376
	3505	3480	3498
	3398	3416	3705

Tabela 5 Wpływ rozmiaru populacji na wyniki dla pliku ftv170.atsp, krzyżowania OX i mutacji insert

ftv170.atsp			
Krzyżowanie OX, Mutacja Reverse			
Rozmiar Populacji	50	150	300
	3901	3475	3827
	3921	3787	3901
	3901	3887	3778
	3921	3734	3842
	3921	3821	3901
	3874	3849	3608
	3921	3705	3921
	3921	3705	3887
	3921	3654	3778
	3887	3701	3921

Tabela 6 Wpływ rozmiaru populacji na wyniki dla pliku ftv170.atsp, krzyżowania OX i mutacji reverse

ftv170.atsp			
Krzyżowanie ESCX, Mutacja Insert			
Rozmiar Populacji	50	150	300
	3923	3365	3205
	3555	3215	3201
	3630	3423	3303
	3718	3334	3200
	3923	3367	3375
	3636	3415	3282
	3850	3465	3359
	3619	3548	3282
	3461	3467	3359
	3810	3321	3338

Tabela 7 Wpływ rozmiaru populacji na wyniki dla pliku ftv170.atsp, krzyżowania ESCX i mutacji insert

ftv170.atsp			
Krzyżowanie ESCX, Mutacja Reverse			
Rozmiar Populacji	50	150	300
	3846	3339	3136
	3923	3390	3407
	3496	3356	3309
	3725	3338	3604
	3566	3240	3248
	3811	3411	3403
	3823	3356	3420
	2757	3436	3358
	3752	3322	3629
	3713	3398	3355

Tabela 8 Wpływ rozmiaru populacji na wyniki dla pliku ftv170.atsp, krzyżowania ESCX i mutacji reverse

rbg403.atsp			
Krzyżowanie OX, Mutacja Insert			
Rozmiar Populacji	50	150	300
	2851	2856	2840
	2906	2909	2967
	2843	2875	2792
	2893	2878	3015
	2866	2874	2867
	2909	2884	2943
	2919	2829	2893
	2884	2864	2860
	2887	2857	2839
	3021	2919	2823

Tabela 9 Wpływ rozmiaru populacji na wyniki dla pliku rbg403.atsp, krzyżowania OX i mutacji insert

rbg403.atsp			
Krzyżowanie OX, Mutacja Reverse			
Rozmiar Populacji	50	150	300
	3500	3471	3390
	3518	3415	3337
	3512	3506	3464
	3511	3497	3328
	3515	3467	3433
	3497	3480	3448
	3502	3506	3458
	3506	3398	3393
	3456	3460	3363
	3481	3476	3278

Tabela 10 Wpływ rozmiaru populacji na wyniki dla pliku rbg403.atsp, krzyżowania OX i mutacji reverse

rbg403.atsp			
Krzyżowanie ESCX, Mutacja Insert			
Rozmiar Populacji	50	150	300
	3526	3477	3470
	3535	3379	3453
	3514	3408	3466
	3519	3440	3444
	3504	3454	3391
	3513	3433	3430
	3248	3324	3562
	3498	3431	3939
	3490	3444	3506
	3462	3517	3517

Tabela 11 Wpływ rozmiaru populacji na wyniki dla pliku rbg403.atsp, krzyżowani ESCX i mutacji insert

rbg403.atsp			
Krzyżowanie ESCX, Mutacja Reverse			
Rozmiar Populacji	50	150	300
	3417	3366	3414
	3522	3313	3407
	3521	3390	3392
	3535	3373	3444
	3436	3498	3403
	3506	3432	3410
	3522	3370	3439
	3492	3421	3438
	3460	3343	3404
	3453	3327	3505

Tabela 12 Wpływ rozmiaru populacji na wyniki dla pliku rbg403.atsp, krzyżowania ESCX i mutacji reverse

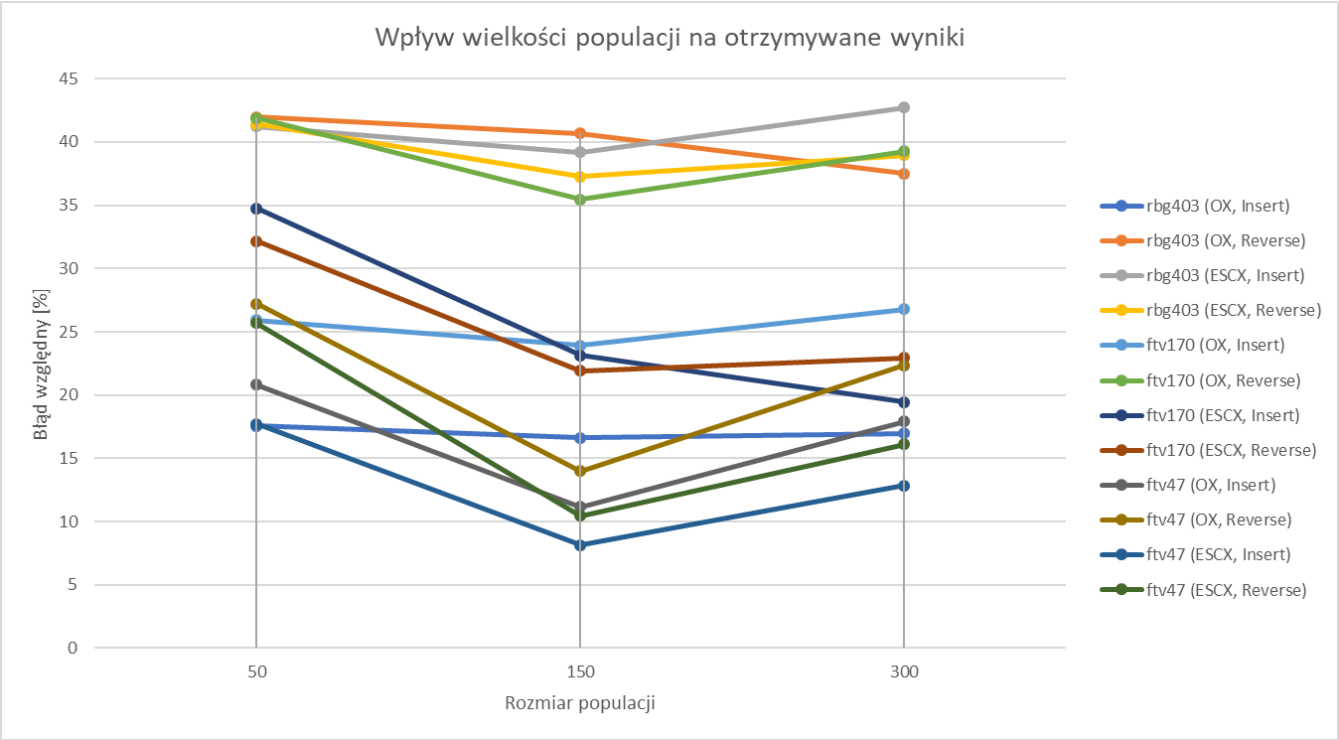

Wykres 1 Wpływ rozmiaru populacji na otrzymywane przez algorytm genetyczny wyniki

Na podstawie przeprowadzonych pomiarów możemy zauważyć, że dla większości przeprowadzonych testów rozmiarem populacji dającym najlepsze wyniki okazała się populacja licząca 150 osobników. Zdecydowanie najgorsza okazała się populacja licząca 50 osobników. Populacja licząca 300 osobników dla dwóch testów okazała się widocznie lepsza od pozostałych rozmiarów populacji jednak dla pozostałych 10 testów uzyskała gorsze rezultaty od populacji z 150 osobnikami. Biorąc pod uwagę wyniki powyższych pomiarów do kolejnych pomiarów zdecydowałem się wybrać populacje liczącą 150 osobników.

10.2 Badanie wpływu współczynnika mutacji na otrzymywane wyniki

a) ftv47.atsp

ftv47.atsp			
Krzyżowanie ESCX, Mutacja Insert			
Współczynnik mutacji	0.01	0.05	0.1
	2019	1830	1950
	1973	1885	1880
	1955	1970	1961
	2019	1911	1967
	2019	1932	1948
	1966	1949	1884
	1948	1944	1790
	1955	2001	1954
	2039	1901	1911
	2058	1966	1901

Tabela 13 Wpływ współczynnika mutacji na wyniki dla pliku ftv47.atsp, krzyżowania ESCX i mutacji insert

ftv47.atsp			
Krzyżowanie ESCX, Mutacja Reverse			
Współczynnik mutacji	0.01	0.05	0.1
	2121	2119	2184
	2050	2132	2018
	2110	2081	2145
	2082	2131	2120
	2176	2091	2002
	2002	2118	2127
	2147	2157	2104
	2122	2129	2127
	2113	2095	2105
	2072	2012	2111

Tabela 14 Wpływ współczynnika mutacji na wyniki dla pliku ftv47.atsp, krzyżowania ESCX i mutacji reverse

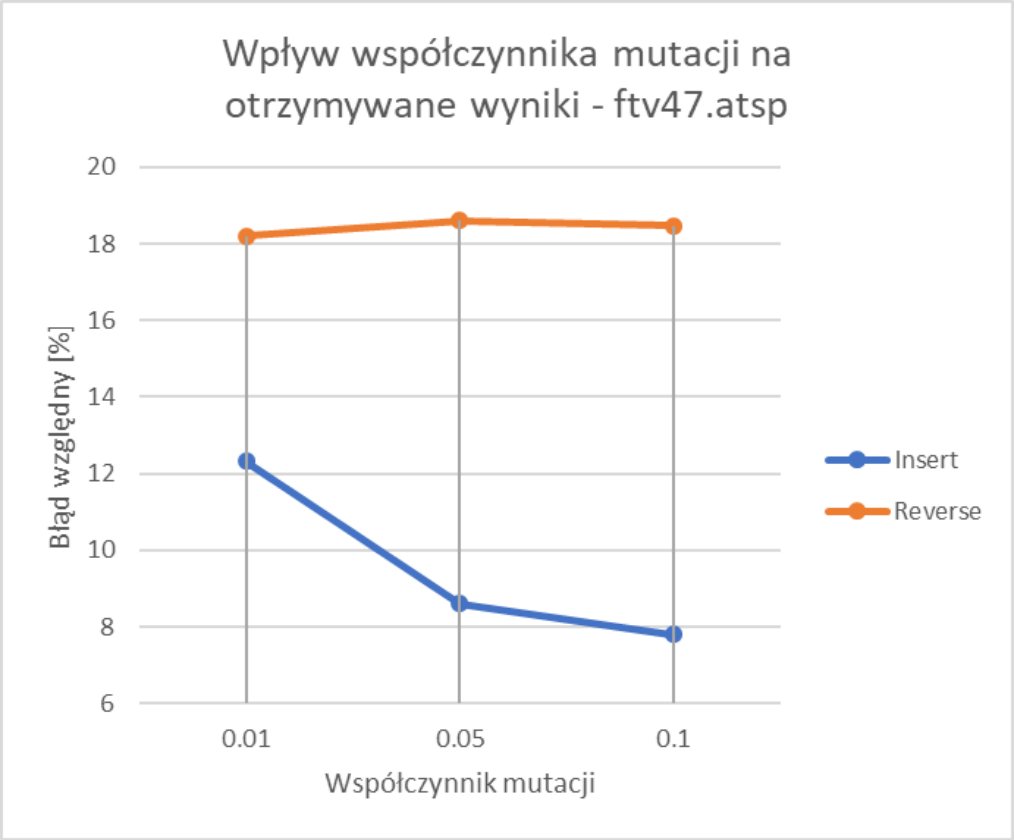

Wykres 2 Wpływ współczynnika mutacji na wyniki dla pliku ftv47.atsp

b) ftv170.atsp

ftv170.atsp			
Krzyżowanie ESCX, Mutacja Insert			
Współczynnik mutacji	0.01	0.05	0.1
	3149	3341	3328
	3354	3436	3264
	3667	3297	3368
	3283	3397	3182
	3508	3400	3457
	3629	3212	3429
	3408	3493	3392
	3491	3458	3273
	3229	3426	3256
	3395	3156	3283

Tabela 15 Wpływ współczynnika mutacji na wyniki dla pliku ftv170.atsp, krzyżowania ESCX i mutacji insert

ftv170.atsp			
Krzyżowanie ESCX, Mutacja Reverse			
Współczynnik mutacji	0.01	0.05	0.1
	3303	3521	3289
	3490	3189	3566
	3496	3389	3337
	3492	3311	3246
	3414	3283	3405
	3573	3292	3286
	3432	3336	3481
	3314	3398	3381
	3437	3456	3247
	3378	3370	3236

Tabela 16 Wpływ współczynnika mutacji na wyniki dla pliku ftv170.atsp, krzyżowania ESCX i mutacji reverse

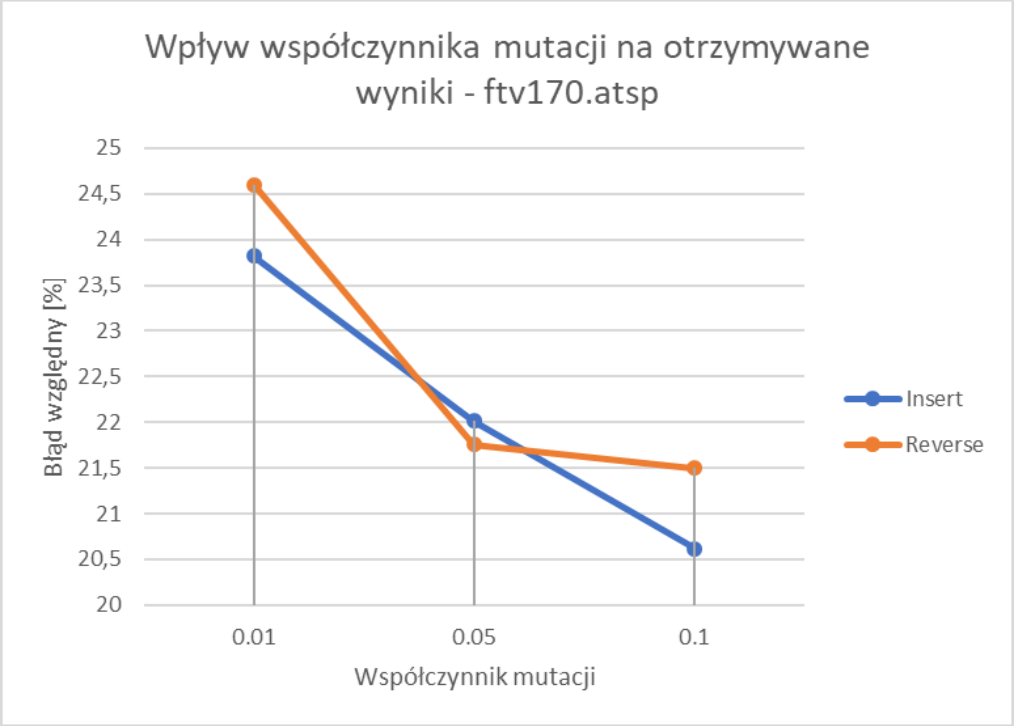

Wykres 3 Wpływ współczynnika mutacji na wyniki dla pliku ftv170.atsp

c) rbg403.atsp

rbg403.atsp			
Krzyżowanie ESCX, Mutacja Insert			
Współczynnik mutacji	0.01	0.05	0.1
	3396	3516	3342
	3364	3353	3409
	3423	3382	3397
	3460	3381	3350
	3426	3407	3401
	3378	3356	3390
	3394	3354	3393
	3384	3410	3385
	3446	3394	3391
	3317	3381	3385

Tabela 17 Wpływ współczynnika mutacji na wyniki dla pliku rbg403.atsp, krzyżowania ESCX i mutacji Insert

rbg403.atsp			
Krzyżowanie ESCX, Mutacja Reverse			
Współczynnik mutacji	0.01	0.05	0.1
	3375	3383	3353
	3406	3381	3421
	3387	3395	3406
	3408	3366	3408
	3426	3432	3415
	3466	3379	3344
	3355	3294	3371
	3328	3466	3358
	3456	3333	3333
	3326	3408	3406

Tabela 18 Wpływ współczynnika mutacji na wyniki dla pliku rbg403.atsp, krzyżowania ESCX i mutacji reverse

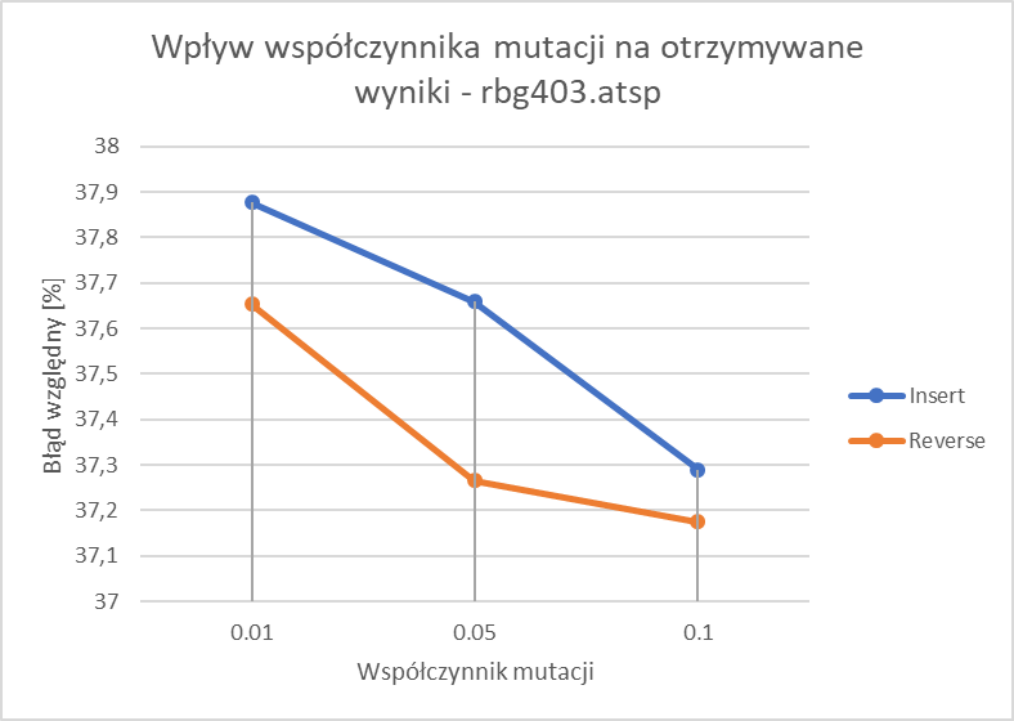

Wykres 4 Wpływ współczynnika mutacji na wyniki dla pliku rbg403.atsp

Na podstawie przeprowadzonych pomiarów możemy zauważyć, że dla plików ftv47.atsp oraz ftv170.atsp lepszą metodą mutacji okazała się metoda Insert, a dla pliku rbg403.atsp była to metoda Reverse. Ze wszystkich przeprowadzonych w tym punkcie pomiarów jedynie dla metody Reverse dla pliku ftv47.atsp wzrost wartości współczynnika pomiarów spowodował pogorszenie uzyskiwanych rezultatów, dla pozostałych przypadków testowych wzrost współczynnika mutacji umożliwiał otrzymywanie coraz to lepszych wyników. W przypadku metody Insert dla pliku ftv47.atsp wzrost ten był znaczący natomiast dla metod Insert i Reverse dla plików ftv170.atsp oraz rbg403.atsp w zrost ten okazał się niewielki.

10.3 Wpływ współczynnika krzyżowania na otrzymywane wyniki

a) ftv47.atsp

ftv47.atsp			
Krzyżowanie OX, Mutacja Insert			
Współczynnik krzyżowania	0,5	0,7	0,9
	1899	2118	1935
	2004	1941	2125
	2088	2060	2144
	2172	2147	2095
	2072	2057	2013
	2123	1941	2095
	1991	2018	2125
	2065	2001	1962
	2069	2173	2004
	2091	2055	2027

Tabela 19 Wpływ współczynnika krzyżowania na wyniki dla pliku ftv47.atsp, krzyżowania OX i mutacji insert

ftv47.atsp			
Krzyżowanie ESCX, Mutacja Insert			
Współczynnik krzyżowania	0,5	0,7	0,9
	1917	1994	1949
	1926	1926	1934
	2061	2019	1970
	1955	2025	1988
	2010	1890	1989
	1947	1893	1951
	2014	1933	1913
	1945	1981	1933
	2156	1932	1798
	1948	1959	1951

Tabela 20 Wpływ współczynnika krzyżowania na wyniki dla pliku ftv47.atsp, krzyżowania ESCX i mutacji Insert

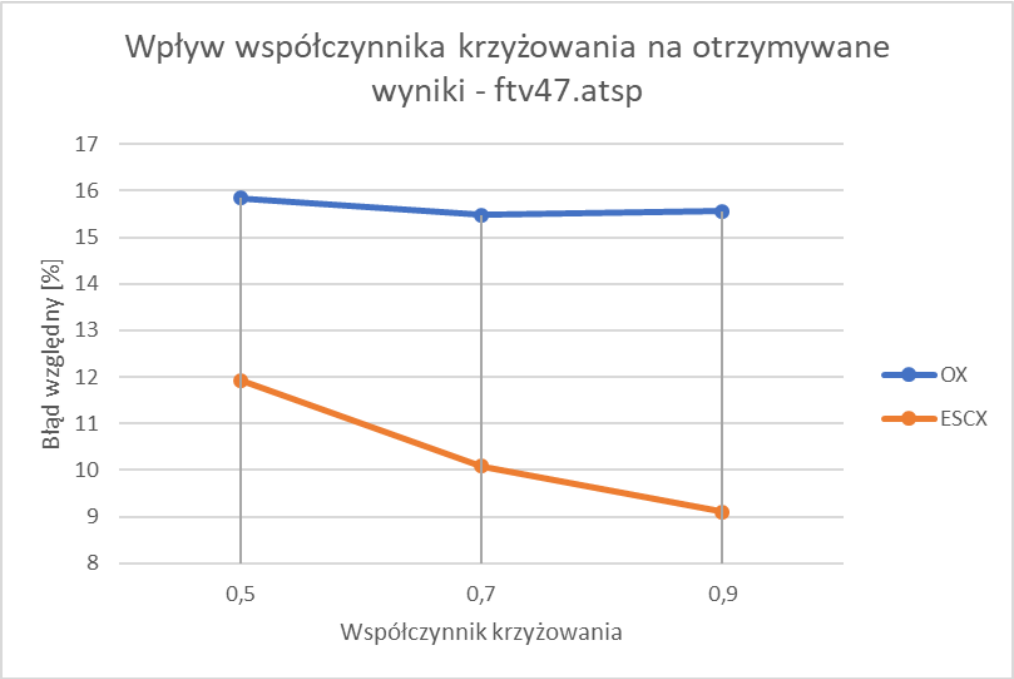

21 Wpływ współczynnika krzyżowania na wyniki dla pliku ftv47.atsp

b) ftv170.atsp

ftv170.atsp			
Krzyżowanie OX, Mutacja Insert			
Współczynnik krzyżowania	0,5	0,7	0,9
	3521	3415	3344
	3506	3506	3399
	3561	3521	3435
	3472	3437	3545
	3527	3509	3465
	3515	3458	3568
	3378	3412	3475
	3460	3516	3472
	3345	3517	3350
	3425	3404	3393

Tabela 22 Wpływ współczynnika krzyżowania na wyniki dla pliku ftv170.atsp, krzyżowania OX i mutacji insert

ftv170.atsp			
Krzyżowanie ESCX, Mutacja Insert			
Współczynnik krzyżowania	0,5	0,7	0,9
	3437	3527	3540
	3450	3221	3361
	3438	3521	3401
	3352	3447	3463
	3239	3374	3316
	3335	3356	3319
	3241	3515	3373
	3336	3471	3616
	3331	3346	3472
	3446	3496	3511

Tabela 23 Wpływ współczynnika krzyżowania na wyniki dla pliku ftv170.atsp, krzyżowania ESCX i mutacji insert

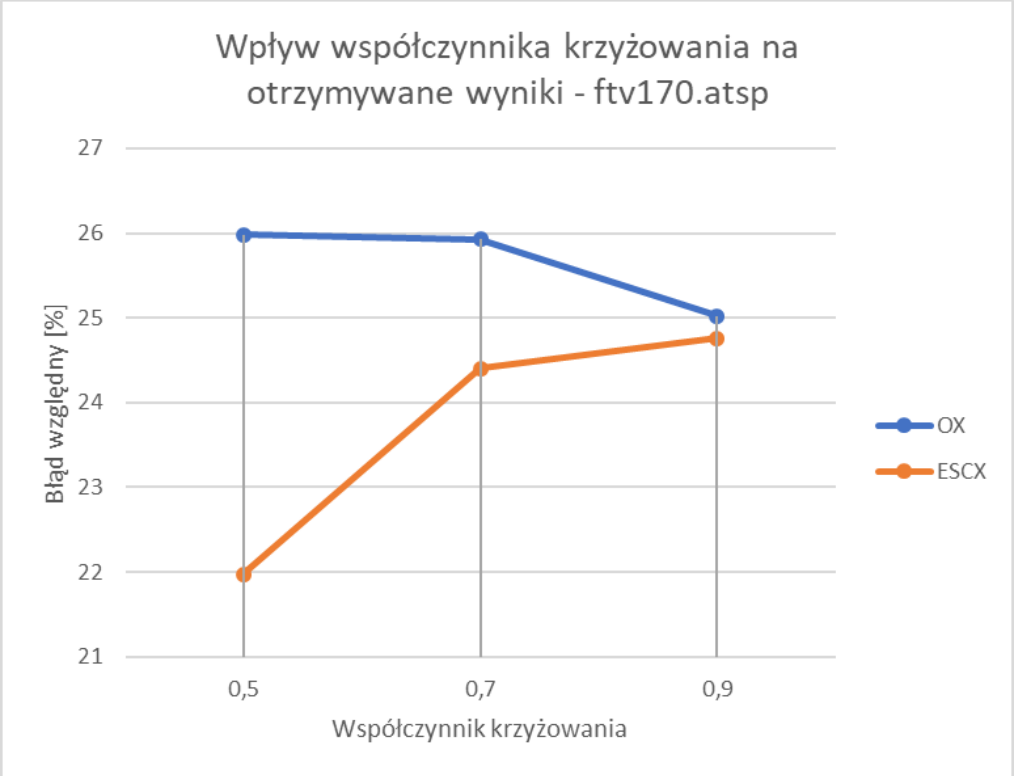

Wykres 5 Wpływ współczynnika krzyżowania na wyniki dla pliku ftv170.atsp

c) rbg403.atsp

rbg403.atsp			
Krzyżowanie OX, Mutacja Insert			
Współczynnik krzyżowania	0,5	0,7	0,9
	2992	3056	2920
	3077	2958	2906
	3070	3003	2999
	3001	3012	2987
	3017	2990	2910
	3039	3042	2983
	2976	2954	2967
	3068	3019	2945
	3019	3060	2955
	3016	2998	2956

Tabela 24 Wpływ współczynnika krzyżowania na wyniki dla pliku rbg403.atsp, krzyżowania OX i mutacji insert

rbg403.atsp			
Krzyżowanie ESCX, Mutacja Insert			
Współczynnik krzyżowania	0,5	0,7	0,9
	3453	3363	3394
	3390	3369	3339
	3398	3410	3381
	3380	3420	3422
	3421	3423	3387
	3348	3380	3407
	3421	3358	3386
	3400	3412	3458
	3365	3385	3256
	3412	3512	3265

Tabela 25 Wpływ współczynnika krzyżowania na wyniki dla pliku rbg403.atsp, krzyżowania ESCX i mutacji insert

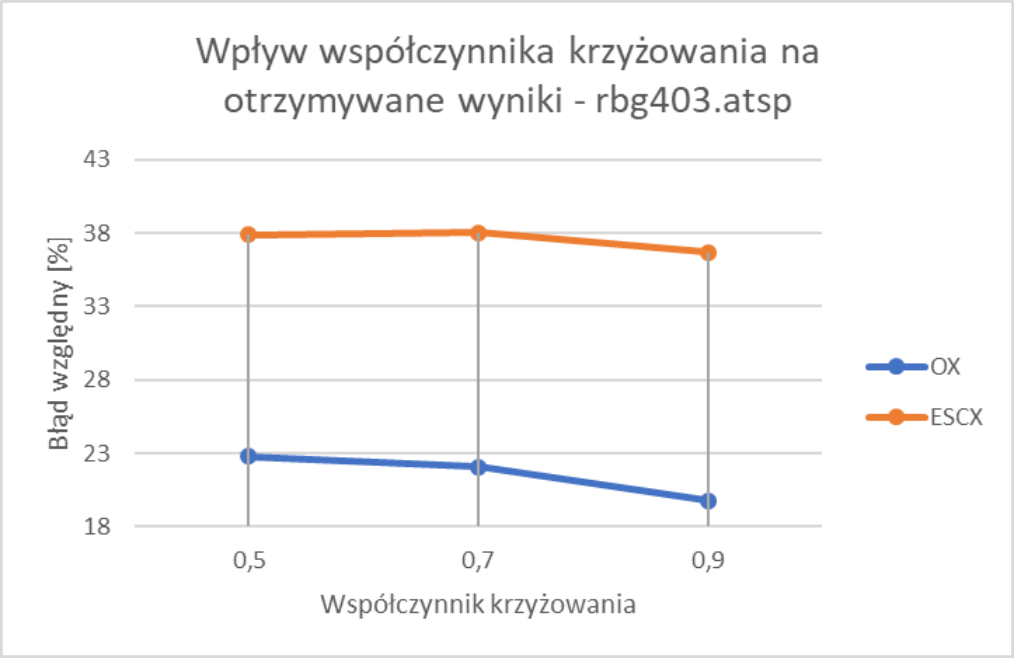

Wykres 6 Wpływ współczynnika krzyżowania na wyniki dla pliku rbg403.atsp

Analizując wyniki pomiarów możemy zauważyć, że dla plików ftv47.atsp oraz ftv170.atsp lepszą metodą krzyżowania osobników okazała się metoda ESCX, a dla pliku rbg403.atsp była to metoda OX. W przypadku pliku rbg403.atsp dla obu metod krzyżowania możemy zauważyć polepszenie jakości otrzymywanych wyników wraz ze wzrostem wartości współczynnika krzyżowania. Dla pliku ftv170.atsp w przypadku krzyżowania OX wraz ze wzrostem współczynnika krzyżowania algorytm zwraca rozwiązania coraz to lepszej jakości natomiast w przypadku krzyżowania ESCX wzrost współczynnika krzyżowania spowodował uzyskanie rozwiązań gorszej jakości. W przypadku metody krzyżowania ESCX dla pliku ftv47.atsp możemy zauważyć zdecydowany wzrost jakości otrzymywanych rozwiązań wraz ze wzrostem współczynnika krzyżowania, dla metody krzyżowania OX wzrost jakości rozwiązań jest praktycznie niezauważalny.

10.4 Porównanie najlepszych wyników algorytmu Tabu Search z najlepszymi wynikami Algorytmu Genetycznego

a) ftv47.atsp

Najlepszym wynikiem uzyskanym przez Tabu Search dla pliku ftv47.atsp był wynik **1776** wraz ze ścieżką:
0-25-1-9-33-27-2-41-43-22-20-38-37-18-17-12-32-7-23-34-13-46-36-14-35-15-16-45-39-19-44-21-40-47-26-42-28-3-24-4-29-30-31-5-6-8-11-10-0

Najlepszym wynikiem uzyskanym przez algorytm genetyczny dla pliku ftv47.atsp był wynik **1790** wraz ze ścieżką:
0-25-1-9-33-27-2-28-3-24-4-29-30-5-31-6-10-8-11-37-38-18-17-12-32-7-23-34-13-46-36-14-35-15-16-45-39-19-44-21-40-47-26-22-41-43-42-20-0

b) ftv170.atsp

Najlepszym wynikiem uzyskanym przez Tabu Search dla pliku ftv170.atsp był wynik **3268** wraz ze ścieżką:
0-1-2-77-73-170-49-50-51-52-53-43-55-54-58-59-60-68-67-167-70-87-86-85-84-69-66-63-64-56-57-62-61-65-88-153-154-89-90-91-94-96-97-98-95-92-93-166-107-106-105-165-163-99-100-102-103-117-118-119-120-121-122-123-162-101-104-114-113-164-127-126-125-129-128-130-131-132-133-134-6-7-8-9-10-76-74-75-11-12-13-17-18-19-20-21-29-22-23-26-27-28-30-31-33-34-156-40-39-38-35-36-157-41-155-42-45-44-46-47-48-168-72-78-82-79-80-81-3-4-5-169-111-110-109-108-83-71-37-158-32-15-159-16-24-25-150-161-160-14-151-152-142-149-148-147-137-136-138-135-139-140-115-116-124-146-145-144-143-141-112-0

Najlepszym wynikiem uzyskanym przez algorytm genetyczny dla pliku ftv170.atsp był wynik **3149** wraz ze ścieżką:
0 77 1 2 3 4 5 169 111 110 109 107 106 105 165 163 99 100 102 103 117 118 119 120 121 122 123 162 101 98 95 92 93 166 108 83 84 69 66 65 64 56 57 62 63 88 153 154 89 90 91 94 96 97 104 114 113 164 127 126 125 129 128 130 135 138 139 140 141 6 7 8 9 10 76 74 75 11 12 18 19 20 158 32 36 157 33 31 30 28 29 16 17 21 22 23 26 27 24 15 159 13 37 38 39 40 35 34 156 44 41 155 42 45 46 47 48 51 52 53 43 55 54 58 59 60 61 68 67 167 70 87 85 86 71 50 49 170 73 168 72 78 82 79 80 81 112 132 133 134 131 115 116 124 137 136 146 145 144 143 147 148 149 161 152 142 14 25 150 160 151 0

c) rbg403.atsp

Najlepszym wynikiem uzyskanym przez Tabu Search dla pliku rbg403.atsp był wyniki **2513** wraz ze ścieżką:
0-206-267-46-23-14-62-13-205-204-24-36-95-334-32-274-83-33-376-68-38-270-19-18-42-402-287-107-61-257-43-34-295-50-56-103-308-394-225-58-8-6-64-3-2-386-47-112-397-5-286-273-370-322-272-28-102-314-11-152-310-29-220-84-281-77-31-52-40-39-78-226-147-79-69-245-81-22-21-82-247-231-288-86-101-153-75-126-27-131-164-15-360-96-66-60-44-87-385-67-94-88-353-263-177-90-72-57-160-25-141-116-232-201-89-140-92-51-49-37-65-301-120-392-351-293-93-145-364-303-71-150-349-73-99-389-187-373-355-115-114-304-260-313-20-302-118-372-278-122-119-168-182-240-219-242-117-213-356-123-318-179-368-251-328-317-104-203-387-384-383-238-146-144-105-391-154-235-113-106-340-163-365-158-339-374-363-289-108-255-109-275-210-110-265-326-258-91-359-254-223-214-192-189-162-48-124-284-290-125-74-216-200-198-307-323-305-215-309-127-191-237-234-228-224-129-130-285-282-357-358-395-132-243-175-291-315-133-1-85-333-30-161-148-325-134-306-319-135-280-279-217-9-312-35-172-26-194-324-320-202-139-4-336-292-329-294-236-227-381-253-268-16-188-299-259-142-248-348-361-229-393-283-277-352-149-347-401-354-342-266-218-197-166-300-97-178-138-297-151-59-111-369-221-199-335-128-208-276-298-171-63-337-230-382-212-176-156-390-311-55-155-7-331-378-398-396-366-321-362-157-269-169-10-170-271-327-233-380-379-195-241-330-343-239-70-345-173-344-332-296-167-174-185-136-193-211-262-261-207-45-375-371-350-252-399-377-180-165-183-17-12-190-100-98-209-41-222-250-246-244-80-264-121-159-143-316-256-249-137-54-367-76-341-186-53-400-181-346-338-388-184-196-0

Najlepszym wynikiem uzyskanym przez algorytm genetyczny dla pliku rbg403.atsp był wynik **2906** wraz ze ścieżką**:**

0 30 332 310 29 77 31 52 40 39 78 226 147 79 69 245 81 22 21 82 247 54 308 26 86 367 75 25 399 163 116 387 67 66 60 44 88 96 94 90 72 57 91 206 160 365 181 1 267 281 92 51 49 37 288 249 301 120 392 351 293 93 145 338 213 41 85 87 56 118 165 95 364 303 71 97 312 260 253 70 218 349 73 99 389 307 359 202 164 15 158 269 131 355 115 114 353 263 102 372 278 122 119 168 103 5 141 356 328 317 104 384 383 197 146 144 105 391 154 106 340 209 363 289 108 255 379 190 212 109 275 210 110 326 258 111 254 223 214 192 189 123 48 358 327 124 284 290 125 74 216 200 198 126 155 323 305 215 309 127 191 128 228 224 129 219 172 273 395 130 187 193 194 196 45 207 4 195 100 98 132 243 175 291 315 133 148 325 134 306 319 135 280 279 136 236 227 320 137 184 321 362 139 336 292 329 294 231 12 178 138 266 201 188 173 344 239 345 299 259 142 229 233 380 234 235 237 238 7 240 149 347 352 150 300 232 251 156 390 151 11 342 297 152 16 324 381 153 401 354 378 337 361 276 298 171 63 377 157 339 179 161 186 53 162 252 371 166 80 10 167 170 334 398 396 357 330 388 348 343 374 271 350 360 176 159 143 397 296 182 230 382 241 113 242 117 208 177 250 366 368 174 180 369 183 217 203 221 199 222 185 220 244 248 246 302 89 304 35 311 313 346 314 59 393 318 333 169 27 335 341 375 277 283 17 285 282 370 286 385 265 402 316 256 23 14 62 13 205 204 24 36 32 274 46 33 376 68 38 270 19 18 42 287 83 43 34 295 50 394 225 58 8 6 64 3 2 61 107 386 47 112 322 257 65 9 84 272 28 101 55 400 140 76 211 121 262 261 264 268 331 20 373 0

11. Wnioski

Algorytm genetyczny jest narzędziem mogącym zostać zastosowanym do wielu problemów optymalizacyjnych. W przypadku problemu komiwojażera najważniejszą rolę w algorytmie genetycznym odgrywa dobrze dobrane połączenie algorytmu selekcji rodziców wraz z algorytmem krzyżowania. Zastosowanie mechanizmu elitaryzmu pozwala zachować w populacji najlepiej przystosowane osobniki co wraz z upływem iteracji algorytmu przyczynia się do tworzenia coraz to lepszych dzieci. Porównując wyniki osiągane przez algorytm genetyczny z wynikami uzyskanymi podczas drugiego etapu projektu przez algorytm Tabu Search, algorytm genetyczny uzyskał lepszy wynik wyłącznie dla pliku ftv170.atsp, dla pozostałych dwóch plików testowych skuteczniejszą metodą rozwiązywania problemu komiwojażera okazał się Tabu Search. Podobnie jak miało to miejsce w przypadku algorytmu Symulowanego Wyżarzania oraz Tabu Search tak samo w przypadku algorytmu genetycznego bardzo ważną rolę w uzyskiwaniu rozwiązań dobrej jakości mają odpowiednio dobrane parametry, które mogą się różnić w zależności od badanej instancji problemu.

12. Bibliografia

- http://aragorn.pb.bialystok.pl/~wkwedlo/EA5.pdf, dostęp 18.01.2021 r.
- https://pl.wikipedia.org/wiki/Algorytm_genetyczny, dostęp 18.01.2021 r.
- https://sound.eti.pg.gda.pl/student/isd/isd03-algorytmy_genetyczne.pdf, dostęp 18.01.2021 r.
- https://www.geeksforgeeks.org/tournament-selection-ga/, dostęp 18.01.2021 r.
- https://www.hindawi.com/journals/cin/2017/7430125/, dostęp 18.01.2021 r.
- https://www.researchgate.net/publication/329643742_Genetic_Algorithm_For_The_Travelling_Salesman_Problem_using_Enhanced_Sequential_Constructive_Crossover_Operator, dostęp 18.01.2021 r.